GUÍA PRÁCTICA DEL ALUMNO

Pipeline de Big Data End-to-End

Proyecto Integrador con Herramientas Open Source & Free-Tier

1. Propósito y Arquitectura General

El objetivo de este proyecto es guiar al estudiante en el diseño, implementación y automatización de un pipeline de procesamiento de datos moderno utilizando exclusivamente herramientas y marcos de trabajo gratuitos. A través de esta guía, identificarás las etapas clave de la ingeniería de datos: Ingesta, Almacenamiento Raw, Procesamiento Batch, Modelado Analítico y Visualización.

Etapa del Pipeline	Marco / Arquitectura	Herramienta Gratuita Sugerida
1. Ingesta de Datos	Data Ingestion (API / Streaming)	Python (Open APIs / Kaggle Hub)
2. Data Lake (Bronze)	Medallion - Raw Storage	GitHub Releases / DuckDB Local
3. Transformación (Silver)	Data Processing & Cleansing	PySpark (Google Colab) / DuckDB
4. Storage (Gold)	Dimensional Modeling & DWH	DuckDB / Google BigQuery (Sandbox)
5. Visualización	Business Intelligence	Streamlit Community Cloud
6. Orquestación	DataOps & Scheduling	GitHub Actions (Cron Jobs)

2. Detalle de Actividades por Fase

Fase 1: Configuración del Entorno y Repositorio

Marco de Trabajo: Versionamiento de Código y Gestión de Proyecto.

- Crear un repositorio público en GitHub estructurado (carpetas: `/src`, `/data`, `/notebooks`).
- Seleccionar una API pública activa (ej. OpenWeather, CoinGecko, Datos Abiertos) o dataset en Kaggle.
- Elaborar el diagrama de arquitectura conceptual en Excalidraw o Mermaid.js.

Fase 2: Ingesta de Datos y Capa Bronze (Raw)

Marco de Trabajo: Arquitectura Medallion - Capa Bronze.

- Escribir script Python `ingest.py` para extraer datos en tiempo real o por lotes.
- Almacenar los datos sin modificaciones en formato JSON o CSV dentro del Data Lake (Capa Raw).
- Implementar registro de errores básicos durante la consulta/extracción de la fuente.

Fase 3: Procesamiento, Limpieza y Capa Silver

Marco de Trabajo: Batch Data Processing & Schema Validation.

- Configurar un cuaderno en Google Colab con **PySpark** o script ejecutable con **DuckDB**.
- Realizar limpieza: deduplicación, imputación de nulos y casteo correcto de tipos de datos.
- Exportar los datos limpios en formato columnar eficiente **Apache Parquet**.

Fase 4: Agregación, Modelado y Capa Gold (DWH)

Marco de Trabajo: Gold Layer & Data Warehousing.

- Diseñar agregaciones analíticas clave (KPIs de negocio, métricas acumuladas).
- Cargar la estructura procesada en una base de datos analítica (DuckDB o BigQuery Sandbox).

Fase 5 y 6: Orquestación, Visualización y Deploy

Marco de Trabajo: DataOps & Business Intelligence Reporting.

- Configurar un workflow en **GitHub Actions** para ejecutar el pipeline vía *CRON schedule*.
- Desarrollar un panel interactivo en **Streamlit** conectado a la Capa Gold.
- Desplegar la aplicación en Streamlit Community Cloud para consumo final.

3. Checklist de Progreso del Alumno

Marca cada hito a medida que completes las actividades del proyecto:

Status	Fase	Actividad / Hito Integrador
☐	Fase 1	Repositorio en GitHub estructurado con Readme inicial y arquitectura.
☐	Fase 1	Fuente de datos (API/Kaggle) seleccionada y probada.
☐	Fase 2	Script de Ingesta en Python funcional guardando en Capa Raw/Bronze.
☐	Fase 2	Estructura de Data Lake organizada correctamente.
☐	Fase 3	Procesamiento con PySpark/DuckDB para tratamiento de nulos y tipos.
☐	Fase 3	Exportación exitosa a archivos comprimidos Apache Parquet (Silver).
☐	Fase 4	Construcción de métricas agregadas y modelo dimensional (Gold).
☐	Fase 4	Carga de tablas finales en DuckDB o BigQuery Sandbox.
☐	Fase 5	Automatización del pipeline con GitHub Actions configurado.
☐	Fase 6	Dashboard interactivo desarrollado con Streamlit.
☐	Fase 6	Despliegue público de la aplicación e informe final documentado.